

## 七、CRF

Lafferty, J., McCallum, A., Pereira, F. (2001). ["Conditional random fields: Probabilistic models for segmenting and labeling sequence data"](#).

**应用领域:** text processing, text classification,  
computer vision, bioinformatics...

**Discriminative Model**

# 概率无向图模型 PUGM MRF

---

- 有向图模型，又称作贝叶斯网络(Directed Graphical Models, **DGM**, Bayesian Network)。
- 使用没有方向的无向边，形成了无向图模型(Undirected Graphical Model, **UGM**), 又被称为马尔科夫随机场或者马尔科夫网络(Markov Random Field, **MRF** or Markov network)

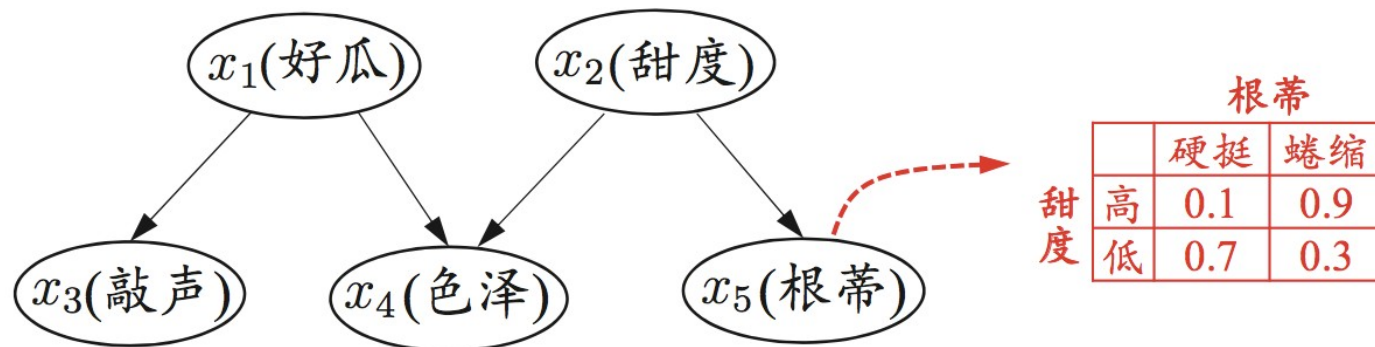
# MRF 和 CRF

□ 设  $X=(X_1, X_2 \dots X_n)$  和  $Y=(Y_1, Y_2 \dots Y_m)$  都是联合随机变量，若随机变量  $Y$  构成一个无向图  $G=(V, E)$  表示的马尔科夫随机场(MRF)，则条件概率分布  $P(Y|X)$  称为条件随机场(Conditional Random Field, CRF)

□ 注：大量文献将MRF和CRF混用，包括经典著作。


# 有向分离

“有向分离” (D-separation)




先将有向图转变为无向图

- V 型结构父结点相连
- 有向边变成无向边




# DGM转换成UGM

- V 型结构父结点相连
- 有向边变成无向边




Bayesian network.




Markov random field.

# DGM转换成UGM





$4 \perp 5 | 2$



条件独立的破坏

# 条件独立的破坏

□ 靠考察是否有  $A \perp B|C$  , 则计算  $U$  的祖先图(ancestral graph) :  $U = A \cup B \cup C$




$$4 \perp 5 | 2$$

# MRF的性质

- 成对马尔科夫性
  - pairwise Markov property
- 局部马尔科夫性
  - local Markov property
- 全局马尔科夫性
  - global Markov property
- 表述说明：随机变量  $Y=(Y_1, Y_2 \dots Y_m)$  构成无向图  $G=(V, E)$ ，结点  $v$  对应的随机变量是  $Y_v$ 。
- (概率无向图模型) 设联合概率分布  $P(Y)$ ，由无向图  $G=(V, E)$  表示，节点表示随机变量，边表示随机变量之间的依赖关系。如果联合概率分布  $P(Y)$  满足成对、局部或全局马尔科夫性，就称此联合概率分布为概率无向图模型 (Probability Undirected Graphical Model, PUGM)，或者马尔科夫随机场 (马尔科夫网络)。



# 考察结点间的独立性



**Pairwise**  $1 \perp 7 | \text{rest}$


**Local**  $1 \perp \text{rest} | 2, 3$

**Global**  $1, 2 \perp 6, 7 | 3, 4, 5$

# 成对马尔科夫性

□ 设  $u$  和  $v$  是无向图  $G$  中任意两个没有边直接连接的结点， $G$  中其他结点的集合记做  $O$ ；则在给定随机变量  $Y_O$  的条件下，随机变量  $Y_u$  和  $Y_v$  条件独立。

□ 即： $P(Y_u, Y_v | Y_O) = P(Y_u | Y_O) * P(Y_v | Y_O)$



**Pairwise**  $1 \perp 7 | \text{rest}$


**Local**  $1 \perp \text{rest} | 2, 3$

**Global**  $1, 2 \perp 6, 7 | 3, 4, 5$

# 局部马尔科夫性

□ 设  $v$  是无向图  $G$  中任意一个结点， $W$  是与  $v$  有边相连的所有结点， $G$  中其他结点记做  $O$ ；则在给定随机变量  $Y_W$  的条件下，随机变量  $Y_v$  和  $Y_O$  条件独立。

□ 即： $P(Y_v, Y_O | Y_W) = P(Y_v | Y_W) * P(Y_O | Y_W)$



**Pairwise**  $1 \perp 7 | \text{rest}$


**Local**  $1 \perp \text{rest} | 2, 3$

**Global**  $1, 2 \perp 6, 7 | 3, 4, 5$

# 全局马尔科夫性

□ 设结点集合 **A**, **B** 是在无向图 G 中被结点集合 **C** 分开的任意结点集合, 则在给定随机变量  $Y_C$  的条件下, 随机变量  $Y_A$  和  $Y_B$  条件独立。

□ 即 :  $P(Y_A, Y_B | Y_C) = P(Y_A | Y_C) * P(Y_B | Y_C)$




**Pairwise**  $1 \perp 7 | \text{rest}$

**Local**  $1 \perp \text{rest} | 2, 3$

**Global**  $1, 2 \perp 6, 7 | 3, 4, 5$

# 三个性质的等价性




- 根据全局马尔科夫性，能够得到局部马尔科夫性；
  - 根据局部马尔科夫性，能够得到成对马尔科夫性；
  - 根据成对马尔科夫性，能够得到全局马尔科夫性；
- 满足这三个性质(或其一)的无向图，称为概率无向图模型。

# 团

---

- 无向图  $G$  中任何两个结点均有边连接的子集，称作  $G$  的团(Clique)。
- 若  $C$  是  $G$  的一个团，并且不能再加入任何一个  $G$  的结点使其成为团，则  $C$  称作  $G$  的最大团(Maximal Clique)。

# 下图的最大团是什么？



- 无向图  $G$  中任何两个结点均有边连接的子集，称作  $G$  的团(Clique)。
- 若  $C$  是  $G$  的一个团，并且不能再加入任何一个  $G$  的结点使其称为团，则  $C$  称作  $G$  的最大团(Maximal Clique)。
- $C1 = \{1, 2, 3\}$ ;
- $C2 = \{2, 3, 4\}$

# Hammersley-Clifford定理

□ UGM 的联合分布可以表示成最大团上的随机变量的函数的乘积的形式；这个操作叫做UGM的因子分解 (Factorization)。

□ UGM 的联合概率分布  $P(Y)$  可以表示成如下形式：

$$P(Y) = \frac{1}{Z} \prod_c \psi_c(Y_c)$$

MRF: Generative Model


$$Z = \sum_Y \prod_c \psi_c(Y_c)$$

□ 其中， $C$  是  $G$  的最大团， $\psi_c(Y_c)$  是  $C$  上定义的严格正函数（通常定义为指数函数），乘积是在 UGM 所有的最大团上进行的，被称作势函数。(Potential Function)。



# Hammersley-Clifford定理

□ UGM 的联合分布可以表示成最大团上的随机变量的函数的乘积的形式；这个操作叫做UGM的因子分解(Factorization)。



$$p(\mathbf{y}|\boldsymbol{\theta}) = \frac{1}{Z(\boldsymbol{\theta})} \underline{\psi_{123}(y_1, y_2, y_3)} \underline{\psi_{234}(y_2, y_3, y_4)} \underline{\psi_{35}(y_3, y_5)}$$

# 条件随机场

□ (条件随机场) 设  $X=(X_1, X_2 \dots X_n)$  和  $Y=(Y_1, Y_2 \dots Y_m)$  都是随机变量, 若随机变量  $Y$  构成一个无向图  $G=(V, E)$  表示的马尔科夫随机场, 即:

$$P(Y_v|X, Y_w, w \neq v) = P(Y_v|X, Y_w, w \sim v)$$

## CRF: Discriminative Model

对任意节点  $v$  成立, 则条件概率分布  $P(Y|X)$  称为条件随机场(Conditional Random Field, CRF)。其中,  $w \sim v$  表示与结点  $v$  相连的所有结点  $w$ ,  $w \neq v$  表示  $v$  以外的所有节点。


□ 定义中并没有要求  $X$  和  $Y$  具有相同的结构。

# 条件随机场


$$P(Y_v|X, Y_w, w \neq v) = P(Y_v|X, Y_w, w \sim v)$$

□ 这时，条件概率  $P(Y|X)$  中， $Y$  表示标记序列（或称状态序列）， $X$  是需要标注的观测序列。

□ 线性链条件随机场的无向图模型      最大团是相邻两个节点的集合



线性链条件随机场




$X$ 和 $Y$ 有相同的图结构的线性链条件随机场

# 线性链条件随机场的定义

□ 设  $X=(X_1, X_2 \dots X_n)$ ,  $Y=(Y_1, Y_2 \dots Y_n)$  均为线性链表示的随机变量序列，若在给定随机变量序列  $X$  的条件下，随机变量序列  $Y$  的条件概率分布  $P(Y|X)$  构成条件随机场，即满足马尔科夫性

$$P(Y_i | X, Y_1, Y_2 \dots Y_n) = P(Y_i | X, Y_{i-1}, Y_{i+1})$$

则称  $P(Y|X)$  为线性链条件随机场。在标注问题中， $X$  表示观测序列， $Y$  表示对应的输出标记序列或称状态序列。



$$X = X_1, \dots, X_{n-1}, X_n$$

# 线性链条件随机场的参数化形式

□ 设  $P(Y|X)$  为线性链条件随机场，则在随机变量  $X$  取值为  $x$  的条件下，随机变量  $Y$  取值为  $y$  的条件概率有以下形式（给定输入序列  $x$ ，对输出序列  $y$  预测的条件概率）：

$$P(y|x) = \frac{1}{Z(x)} \exp \left\{ \sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right\}$$

其中， $Z = \sum_y \exp \left( \sum_j \sum_{i=1}^{n-1} \lambda_j t_j(y_{i+1}, y_i, x, i) + \sum_k \sum_{i=1}^n \mu_k s_k(y_i, x, i) \right)$

是规范化因子，求和是在所有可能的输出序列上进行的， $t_j$  和  $s_k$  是特征函数， $\lambda_j$  和  $\mu_k$  是对应的权值。

# 条件随机场-特征函数

y	{y <sub>1</sub>	y <sub>2</sub>	y <sub>3</sub>	y <sub>4</sub>	y <sub>5</sub>	y <sub>6</sub> }
	[D]	[N]	[V]	[P]	[D]	[N]

x	{x <sub>1</sub>	x <sub>2</sub>	x <sub>3</sub>	x <sub>4</sub>	x <sub>5</sub>	x <sub>6</sub> }
	The boy knocked at the watermelon.					

□ 条件概率可被定义为：

$$P(y|x) = \frac{1}{Z(x)} \exp \left\{ \sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right\}$$

- $t_j(y_{i-1}, y_i, x, i)$  是定义在观测序列的两个相邻标记位置上的转移特征函数(transition, 边上的特征函数), 用于刻画相邻标记变量之间的相关关系以及观测序列对它们的影响

$$t_k(y_{i-1}, y_i, x, i) = \begin{cases} 1, & \text{if } y_{i-1} = [N], y_i = [V], \text{ and } x_i = \text{"knocked"} \\ 0, & \text{otherwise.} \end{cases}$$

表示第*i*个观测值  $x_i$  为单词'knocked'时, 相应的标记  $y_{i-1}, y_i$  很可能分别为[N], [V].

# 条件随机场-特征函数

□ 条件概率可被定义为：

y	{y <sub>1</sub> y <sub>2</sub> y <sub>3</sub> y <sub>4</sub> y <sub>5</sub> y <sub>6</sub> }					
	[D]	[N]	[V]	[P]	[D]	[N]
x	{x <sub>1</sub> x <sub>2</sub> x <sub>3</sub> x <sub>4</sub> x <sub>5</sub> x <sub>6</sub> }					
	The boy knocked at the watermelon.					

$$P(y|x) = \frac{1}{Z(x)} \exp \left\{ \sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right\}$$

- $s_k(y_i, x, i)$  是定义在观测序列的标记位置  $i$  上的 **状态特征函数 (status)**，用于刻画观测序列对标记变量的影响

$$s_k(y_i, x, i) = \begin{cases} 1, & \text{if } y_i = [V] \text{ and } x_i = \text{"knock"}; \\ 0, & \text{otherwise,} \end{cases}$$

- 表示第  $i$  个观测值  $x_i$  为单词 'knocked' 时，它相对应的标记很可能为  $[V]$ .

# 参数说明

---

- $t_k$  和  $s_l$  都依赖于位置，是局部特征函数；
- 通常， $t_k$  和  $s_l$  取值为1或者0；满足特征条件时取1，否则取0；
- CRF 完全由特征函数  $t_k$ 、 $s_l$  和对应的权值  $\lambda_k$ 、 $\mu_l$  确定。
- 线性链 CRF 属于对数线性模型 (log linear model)。



# CRF的两个问题

---

## □ CRF的概率计算问题

- 前向后向算法

## □ CRF的学习算法

- 改进的迭代尺度算法 (IIS, Improved Iterative Scaling)
- 拟牛顿法

## □ CRF的预测算法

- Viterbi算法

# 参考文献

---

- ❑ Machine Learning: A Probabilistic Perspective, Kevin P. Murphy, The MIT Press, 2012
- ❑ Conditional Random Fields: An Introduction, Hanna M. Wallach, 2004
- ❑ An Introduction to Conditional Random Fields, Charles Sutton, Andrew McCallum, 2012
- ❑ 统计学习方法, 李航著, 清华大学出版社, 2012年
- ❑ Pattern Recognition and Machine Learning Chapter 13, Bishop M, Springer-Verlag, 2006
- ❑ Radner L, Juang B. An introduction of hidden markov Models. IEEE ASSP Magazine, January 1986